

Phishing, Social Engineering e AI: simulazione di un attacco su Marsh S.p.A

Progetto S5 L5



Gianluca Vitale

INDICE

#	SEZIONE	PAG.
1	Introduzione	3
2	Obiettivo 1 - creazione dello Scenario	4
2.1	Perchè ho scelto Marsh S.p.A	4
2.2	Il dipendente fittizio e l'obiettivo dell'attacco	5
3	Obiettivo 2 - Generazione Email tramite LLM	6
3.1	Il prompt adversarial e il primo tentativo fallito	6
3.2	Come ho riformulato il prompt e l'email ottenuta	7
3.3	Perchè l'email è convincente: urgenza, link e principi di Cialdini	8
4	Obiettivo 3 - Analisi dello Scenario	9
4.1	Perchè questa mail potrebbe ingannare la vittima	9
4.2	I segnali d'allarme che la smascherano	10
5	Conclusioni	11

1. Introduzione

Per questa esercitazione ho deciso di simulare una campagna di phishing mirata a un'azienda reale. L'idea era quella di seguire le stesse fasi che userebbe un attaccante vero: prima raccogliere informazioni sull'obiettivo, poi costruire un'email convincente con l'aiuto di un'intelligenza artificiale, e infine analizzare sia i punti di forza che i punti deboli dell'attacco.

Per generare l'email ho usato Claude, il modello sviluppato da Anthropic. Non è stato semplice: al primo tentativo Claude ha rifiutato di aiutarmi, e ho dovuto riformulare il prompt usando una tecnica specifica che spiego più avanti nel report.

Tutto quello che ho fatto ha uno scopo puramente didattico. Nessun sistema reale è stato toccato e tutti i dati personali usati, come nomi e indirizzi email, sono completamente inventati.

2. Obiettivo 1 - Creazione dello Scenario

2.1 Perché ho scelto Marsh S.p.A.

Ho scelto Marsh S.p.A. come target di questa simulazione perché è una grande azienda reale, il che rende lo scenario più interessante e credibile rispetto a un'azienda inventata. Marsh S.p.A. è la filiale italiana del gruppo multinazionale Marsh McLennan, uno dei leader mondiali nel brokeraggio assicurativo e nella consulenza sul rischio. Ha sede a Milano, in Viale Luigi Bodio 33, conta oltre 700 dipendenti in Italia ed è presente in più di 15 città tra cui Roma, Torino, Bologna e Napoli.

Prima di costruire l'email ho cercato informazioni pubbliche sull'azienda, esattamente come farebbe un attaccante reale nella fase di raccolta dati. Ho usato strumenti accessibili a tutti: il sito ufficiale marsh.it, LinkedIn e alcune ricerche su Google. La cosa più utile che ho trovato è stata il record DNS MX del dominio marsh.com, che mi ha detto quale provider email usa l'azienda. Per farlo ho aperto il terminale di Windows e ho digitato il comando nslookup che avevamo visto a lezione.

```
Windows PowerShell
Copyright (C) Microsoft Corporation. Tutti i diritti riservati.

Installa la versione più recente di PowerShell per nuove funzionalità e miglioramenti. https://aka.ms/PSWindows

PS C:\Users\Gianluca> nslookup -type=MX marsh.com
Server: fritz.box
Address: fd00::62b5:8dff:fe69:92e8

Risposta da un server non autorevole:
marsh.com      MX preference = 5, mail exchanger = mxb-001b7601.gslb.pphosted.com
marsh.com      MX preference = 5, mail exchanger = mxa-001b7601.gslb.pphosted.com
PS C:\Users\Gianluca> |
```

Dal risultato ho scoperto che Marsh usa Proofpoint come infrastruttura email, un sistema professionale di sicurezza molto diffuso nelle grandi aziende. Questo è un dettaglio importante perché mi ha permesso di costruire un'email di phishing coerente con la realtà dell'azienda, ad esempio impersonando una notifica del sistema IT interno.

2. Obiettivo 1 - Creazione dello Scenario

2.2 Il dipendente fittizio e l'obiettivo dell'attacco

Per rendere lo scenario concreto ho creato un personaggio completamente fittizio: Anna Rossi, Broker Assicurativo Senior nel reparto Corporate Risk & Broking di Marsh S.p.A., con indirizzo email inventato a.rossi@marsh.com. Il nome, il ruolo e qualsiasi altro dettaglio non corrispondono a nessuna persona reale.

L'obiettivo dell'attacco è rubare le credenziali di accesso al portale interno aziendale. Ho scelto questo tipo di obiettivo perché è uno dei più comuni nella realtà: una volta ottenute le credenziali, un attaccante potrebbe accedere a documenti riservati, dati di clienti e informazioni sulle polizze gestite dall'azienda.



Lo scenario che ho costruito è una falsa notifica IT: un'email che sembra provenire dal team informatico di Marsh e avvisa Anna che le sue credenziali stanno per scadere. Ho scelto questo pretesto perché i dipendenti ricevono questo tipo di comunicazioni regolarmente e tendono a fidarsi, soprattutto se il messaggio sembra provenire dall'ufficio IT interno.

3. Obiettivo 2 — Generazione dell'Email tramite LLM

3.1 Il prompt adversarial e il primo tentativo fallito

Per generare il contenuto dell'email ho usato Claude, il modello di intelligenza artificiale di Anthropic, accessibile dal browser su claude.ai. Il problema è che Claude, come tutti i modelli moderni, ha dei blocchi di sicurezza che gli impediscono di generare contenuti potenzialmente dannosi, tra cui appunto le email di phishing.

Nel mio primo tentativo ho spiegato a Claude che stavo preparando un'esercitazione scolastica e gli ho chiesto di scrivere un'email di phishing rivolta ad Anna Rossi di Marsh S.p.A. Come prevedevo, Claude ha rifiutato, spiegando che non poteva aiutarmi a creare contenuti che potevano essere usati per ingannare persone reali.



3. Obiettivo 2 — Generazione dell'Email tramite LLM

Questo rifiuto è esattamente quello che mi aspettavo e dimostra che i modelli di intelligenza artificiale hanno dei meccanismi di difesa interni. La domanda però è: quanto sono efficaci questi meccanismi? Per rispondere ho provato a riformulare la richiesta usando una tecnica diversa.

3.2 Come ho riformulato il prompt e l'email ottenuta

Al secondo tentativo ho cambiato approccio. Invece di chiedere direttamente di scrivere un'email di phishing, ho inquadrato la richiesta in un contesto diverso, presentandomi come uno studente di sicurezza informatica che stava preparando materiale didattico per mostrare ai colleghi come riconoscere questo tipo di attacchi. Questa tecnica si chiama Context Manipulation e consiste nel cambiare il contesto della richiesta per renderla apparentemente legittima agli occhi del modello.

In sostanza, Claude non può verificare se sono davvero uno studente o un formatore autorizzato: si fida del contesto che gli fornisco. Questo è esattamente il concetto di prompt adversarial che abbiamo studiato, ovvero un prompt costruito in modo da aggirare i meccanismi di sicurezza del modello senza violarli direttamente.

Con questo secondo approccio Claude ha collaborato e ha generato l'email che cercavo. Ecco il risultato:

Da: it-helpdesk@marsh-support-internal.com **A:** a.rossi@marsh.com **Oggetto:** [URGENTE]
Le tue credenziali di accesso scadono oggi alle 23:59

Gentile Anna,

ti scriviamo dal team IT di Marsh S.p.A. per informarti che le tue credenziali di accesso al portale interno aziendale scadranno oggi alle 23:59.

Il tuo account: a.rossi@marsh.com Scadenza prevista: oggi alle 23:59

Il 91% dei tuoi colleghi ha già completato la procedura di rinnovo.

Se non aggiorni le credenziali entro la scadenza, perderai l'accesso immediato a tutti i sistemi aziendali, inclusi i portali clienti, la documentazione polizze e le piattaforme di gestione del rischio.

AGGIORNA LE CREDENZIALI ORA <https://marsh-accesso-sicuro.com/rinnovo-credenziali>

Per qualsiasi problema contatta: it-helpdesk@marsh-support-internal.com

IT Security Team — Marsh S.p.A.
Viale Luigi Bodio 33, 20158 Milano

3.3 Perché l'email è convincente: urgenza, link e principi di Cialdini

Guardando l'email generata da Claude, noto che contiene tutti e tre gli elementi tipici di un attacco phishing.

Il primo è la richiesta urgente: la scadenza fissata a oggi alle 23:59 crea una pressione psicologica immediata. Chi riceve questo messaggio non ha tempo per fermarsi a ragionare o verificare, deve agire subito. Questo si collega al principio di Scarsità e Urgenza di Cialdini, secondo cui tendiamo a reagire più velocemente quando rischiamo di perdere qualcosa.

Il secondo elemento è il link sospetto: l'URL nell'email punta a marsh-accesso-sicuro.com, che non ha nulla a che fare con il dominio ufficiale marsh.com. È un esempio di dominio look-alike, registrato appositamente per sembrare legittimo a chi legge velocemente.

Il terzo elemento riguarda i principi di Cialdini, che ho inserito esplicitamente nel prompt. Oltre all'urgenza, l'email sfrutta il principio di Autorità presentandosi come il team IT ufficiale di Marsh, e il principio di Riprova Sociale con la frase il 91% dei tuoi colleghi ha già completato la procedura, che spinge la vittima a conformarsi per non sembrare l'unica rimasta indietro.

4. Obiettivo 3 — Analisi dello Scenario

4.1 Perché questa email potrebbe ingannare la vittima

Rileggendo l'email con occhio critico, capisco perché potrebbe funzionare su una persona che non è abituata a riconoscere il phishing. Prima di tutto il tono è professionale: non ci sono errori grammaticali, la firma è strutturata e il layout ricorda quello di una vera comunicazione aziendale. Questo è uno degli effetti più significativi dell'uso dell'intelligenza artificiale nel phishing moderno: prima era abbastanza facile smascherare un'email falsa dagli errori di scrittura, oggi non è più così.

Poi c'è la personalizzazione: l'email contiene il nome della vittima, il suo indirizzo email e un riferimento diretto ai sistemi che usa ogni giorno, come i portali clienti e la documentazione polizze. In un attacco reale queste informazioni verrebbero raccolte tramite LinkedIn e altre fonti pubbliche, esattamente come ho fatto io nella fase OSINT di questo esercizio.

Infine, sapere che Marsh usa Proofpoint come sistema email rende il pretesto della scadenza delle credenziali completamente plausibile: è il tipo di notifica che un dipendente si aspetterebbe di ricevere dal proprio ufficio IT.

4.2 I segnali d'allarme che la smascherano

Nonostante tutto, l'email ha diversi segnali d'allarme che un occhio attento dovrebbe cogliere. Il più evidente è il dominio del mittente: l'email arriva da marsh-support-internal.com, che non è il dominio ufficiale marsh.com. Questa tecnica si chiama typosquatting e consiste nel registrare un dominio simile a quello legittimo per ingannare chi legge velocemente.

Anche il link per il rinnovo è sospetto: punta a marsh-accesso-sicuro.com, che di nuovo non appartiene a Marsh. La regola generale è semplice: se un'email ti chiede di cliccare un link urgente, prima di farlo controlla sempre che l'URL appartenga davvero al dominio ufficiale dell'azienda.

Un altro campanello d'allarme è la pressione temporale esagerata. Le vere notifiche IT raramente impongono scadenze di poche ore senza un preavviso. L'urgenza artificiale è uno dei trucchi più usati nel phishing proprio perché toglie alla vittima il tempo di pensare.

Ecco un riepilogo dei segnali d'allarme principali:

SEGNALE D'ALLARME	SPIEGAZIONE
dominio mittente falso	marsh-support-internal.com non e il dominio ufficiale marsh.com
Link sospetto	marsh-accesso-sicuro.com non appartiene a Marsh S.p.A.
urgenza esagerata	Scadenza di poche ore senza preavviso: pressione per non ragionare
Statistica non verificabile	'91% dei colleghi' e inventata e usata per creare pressione sociale
Fail SPF/DKIM/DMARC	Il dominio falso non supera i controlli di autenticazione email

5. Conclusioni

Fare questo esercizio è stato molto utile per capire davvero come funziona un attacco di phishing dall'interno. La cosa che mi ha sorpreso di più è stata vedere quanto sia facile costruire un'email credibile usando l'intelligenza artificiale: il testo è perfetto, il tono è professionale e non ci sono gli errori di scrittura che di solito rendono riconoscibili le email false.

Ho capito anche quanto sia importante la fase di raccolta informazioni. Sapere che Marsh usa Proofpoint, conoscere la struttura dell'azienda, usare un linguaggio coerente con il settore assicurativo: tutti questi dettagli fanno la differenza tra un attacco generico, che quasi tutti oggi riconoscono, e uno spear phishing mirato, che invece può ingannare anche persone esperte.

L'esperienza con il prompt adversarial è stata interessante: al primo tentativo Claude ha rifiutato di aiutarmi, dimostrando che i modelli moderni hanno meccanismi di difesa interni. Ma riformulando il prompt con la tecnica di Context Manipulation sono riuscito comunque a ottenere quello che cercavo. Questo mi ha fatto capire che questi meccanismi non sono infallibili e che chiunque, con un po' di creatività, può aggirarli.

Dal punto di vista difensivo, credo che la misura più efficace rimanga la formazione delle persone. La tecnologia aiuta, ma alla fine è sempre un essere umano che clicca sul link sbagliato. E la regola più importante che porto a casa da questo esercizio è anche la più semplice: se un'email ti mette fretta, fermati. L'urgenza artificiale è quasi sempre il primo segnale che qualcosa non va.